

Procesamiento ETL y análisis de ventas de Gaseosas Poderosas

Evaluación práctica de la Unidad 1

Reconociendo lo aprendido

Fundamentos de Bigdata

Santiago Restrepo Torres

Angi Katherin Ruiz Arango

Estiven Cano Rendón

Institución Universitaria Pascual Bravo

23 de septiembre de 2026

Tabla de Contenido

<i>1 Descripción de la tarea.....</i>	<i>4</i>
<i>2 Diagrama de entidad relación de Chen.....</i>	<i>5</i>
<i>3 Diccionario de datos.....</i>	<i>6</i>
<i>regiones.....</i>	<i>6</i>
<i>productos.....</i>	<i>6</i>
<i>departamentos.....</i>	<i>7</i>
<i>municipios.....</i>	<i>8</i>
<i>operaciones.....</i>	<i>9</i>
<i>temporal.....</i>	<i>10</i>
<i>tamano.....</i>	<i>11</i>
<i>4 Corrida del algoritmo ETL.....</i>	<i>12</i>
<i>5 Incorporación de la región.....</i>	<i>13</i>
<i>6 Detección y corrección de registros.....</i>	<i>14</i>
<i>7 Consultas SQL.....</i>	<i>17</i>
<i>8 Resultados y gráficos.....</i>	<i>24</i>
<i>8 1 Ocho departamentos con mayor monto.....</i>	<i>24</i>
<i>8 2 Quince municipios de Antioquia con más unidades.....</i>	<i>26</i>
<i>8 3 Cinco departamentos con más MANZALOCA.....</i>	<i>28</i>
<i>8 4 Cinco municipios con menor monto.....</i>	<i>29</i>

<i>8 5 Unidades por producto y región</i>	<i>30</i>
<i>8 6 Monto por producto en Antioquia.....</i>	<i>36</i>
<i>10 Tiempo y tamaño de procesamiento</i>	<i>38</i>
<i>11 Análisis de los resultados.....</i>	<i>39</i>
<i>12 Diagrama de flujo del programa ETL</i>	<i>42</i>
<i> Pseudocódigo.....</i>	<i>45</i>
<i>13 Conclusiones</i>	<i>48</i>
<i>14 Video explicativo.....</i>	<i>51</i>
<i>Referencias.....</i>	<i>52</i>


1 Descripción de la tarea

En este trabajo organizamos y analizamos las ventas del caso Gaseosas Poderosas, empresa ficticia con sede en Támesis, Antioquia. Partimos del archivo de departamentos y municipios y de las 10.000 operaciones suministradas. Adaptamos el programa de extracción, transformación y carga de datos (ETL), incorporamos las regiones, corregimos los registros con problemas y ejecutamos las seis consultas solicitadas.

La base conserva las 10.000 operaciones. Corregimos 30 registros y dejamos documentada la causa de cada cambio. Con los datos limpios obtuvimos 1.007.755 unidades y un monto de COP 929.809.400

2 Diagrama de entidad relación de Chen

Entidades y relaciones del caso - Link a draw.io original; [LINK](#)



3 Diccionario de datos

regiones

Estructura de regiones

<i>Campo</i>	<i>Tipo y tamaño</i>	<i>NULL / defecto</i>	<i>Claves y valores</i>
<i>id_region</i>	<i>integer / 4 B</i>	<i>No / Sin valor por defecto</i>	<i>PK. Enteros de 1 a 6.</i>
<i>nombre</i>	<i>varchar(70)</i>	<i>No / Sin valor por defecto</i>	<i>UNIQUE. Nombre de la región del CSV.</i>

productos

Estructura de productos

<i>Campo</i>	<i>Tipo y tamaño</i>	<i>NULL / defecto</i>	<i>Claves y valores</i>
<i>id_producto</i>	<i>integer / 4 B</i>	<i>No / Sin valor por defecto</i>	<i>PK. 1, 2, 3 o 4.</i>
<i>nombre</i>	<i>varchar(20)</i>	<i>No / Sin valor por defecto</i>	<i>COLOMBIANITA, MANZALOCA, MANGOSON o NARANJITA.</i>
<i>precio</i>	<i>integer / 4 B</i>	<i>Sí / 0</i>	<i>CHECK > 0. COP 1.200, 1.000, 900 o 600, respectivamente.</i>

departamentos**Tabla 3***Estructura de departamentos*

Campo	Tipo y tamaño	NULL / defecto	Claves y valores
<i>id_departamento</i>	<i>integer / 4 B</i>	<i>No / Sin valor por defecto</i>	<i>PK. 57 + código DANE de 2 dígitos.</i>
<i>nombre</i>	<i>varchar(70)</i>	<i>No / Sin valor por defecto</i>	<i>Nombre del departamento o Bogotá D. C.</i>
<i>abb</i>	<i>varchar(3)</i>	<i>Sí / Sin valor por defecto</i>	<i>No suministrado.</i>
<i>codigo_dane</i>	<i>varchar(10)</i>	<i>Sí / "</i>	<i>Código del CSV conservado como texto.</i>
<i>codigo_region</i>	<i>integer / 4 B</i>	<i>Sí / 0</i>	<i>FK → regiones.id_region; valores 1 a 6.</i>
<i>poblacion</i>	<i>integer / 4 B</i>	<i>Sí / 0</i>	<i>0 en el archivo base; no hay población utilizable.</i>

UNIQUE adicional: (id_departamento, codigo_region). Permite validar la pareja de departamento y región de cada operación.

municipios***Tabla 4******Estructura de municipios***

<i>Campo</i>	<i>Tipo y tamaño</i>	<i>NULL / defecto</i>	<i>Claves y valores</i>
<i>id_departamento</i>	<i>integer / 4 B</i>	<i>No / Sin valor por defecto</i>	<i>FK → departamentos.id_departamento.</i>
<i>id_municipio</i>	<i>integer / 4 B</i>	<i>No / Sin valor por defecto</i>	<i>PK. ID del departamento + consecutivo de 3 dígitos.</i>
<i>nombre</i>	<i>varchar(70)</i>	<i>No / Sin valor por defecto</i>	<i>Nombre del municipio en el CSV.</i>
<i>abb</i>	<i>varchar(5)</i>	<i>Sí / Sin valor por defecto</i>	<i>Abreviatura no suministrada; queda NULL.</i>
<i>codigo_dane</i>	<i>varchar(10)</i>	<i>Sí / "</i>	<i>Texto original; conserva el punto separador.</i>
<i>poblacion</i>	<i>integer / 4 B</i>	<i>Sí / 0</i>	<i>0 por defecto; no representa una población medida.</i>

UNIQUE adicional: (id_municipio, id_departamento). La FK compuesta de operaciones exige que ambos códigos correspondan al mismo municipio.

operaciones

Tabla 5

Estructura de operaciones

Campo	Tipo y tamaño	NULL / defecto	Claves y valores
<i>id_registro</i>	<i>integer / 4 B</i>	<i>No / Sin valor por defecto</i>	<i>PK. 10001 a 20000 en este conjunto.</i>
<i>id_departamento</i>	<i>integer / 4 B</i>	<i>No / Sin valor por defecto</i>	<i>Parte de FK compuestas hacia municipios y departamentos.</i>
<i>id_municipio</i>	<i>integer / 4 B</i>	<i>No / Sin valor por defecto</i>	<i>FK junto con id_departamento → municipios.</i>
<i>id_producto</i>	<i>integer / 4 B</i>	<i>No / Sin valor por defecto</i>	<i>FK → productos.id_producto.</i>
<i>fecha</i>	<i>date / 4 B</i>	<i>No / Sin valor por defecto</i>	<i>Fecha válida; presentación AAAA-MM-DD.</i>
<i>cantidad</i>	<i>integer / 4 B</i>	<i>No / 0</i>	<i>CHECK > 0; unidades enteras.</i>
<i>estado</i>	<i>varchar(1)</i>	<i>Sí / Sin valor por defecto</i>	<i>Se conserva 'F'; el material no define su significado.</i>
<i>id_region</i>	<i>integer / 4 B</i>	<i>No / Sin valor por defecto</i>	<i>FK → regiones; además se valida su correspondencia con el departamento.</i>
<i>validacion</i>	<i>varchar(10)</i>	<i>No / 'valido'</i>	<i>'valido' o 'modificado', según CHECK.</i>
<i>causa_modificacion</i>	<i>text / variable</i>	<i>No / ''</i>	<i>Vacía para válido; explicación obligatoria para modificado.</i>

Las FK compuestas son (*id_municipio, id_departamento*) → municipios y (*id_departamento, id_region*) → departamentos. El CHECK de validación exige una causa cuando el registro fue modificado.

temporal*Estructura de temporal*

<i>Campo</i>	<i>Tipo y tamaño</i>	<i>NULL / defecto</i>	<i>Claves y valores</i>
<i>codigo_dep</i>	<i>varchar(10)</i>	<i>Sí / Sin valor por defecto</i>	<i>Texto DANE del departamento.</i>
<i>codigo_mun</i>	<i>varchar(10)</i>	<i>Sí / Sin valor por defecto</i>	<i>Texto DANE del municipio.</i>
<i>codigo_region</i>	<i>integer / 4 B</i>	<i>Sí / Sin valor por defecto</i>	<i>Código 1 a 6 calculado por getCodigoRegion.</i>
<i>departamento</i>	<i>text / variable</i>	<i>Sí / Sin valor por defecto</i>	<i>Nombre recibido en el CSV.</i>
<i>municipio</i>	<i>text / variable</i>	<i>Sí / Sin valor por defecto</i>	<i>Nombre recibido en el CSV.</i>
<i>region</i>	<i>text / variable</i>	<i>Sí / Sin valor por defecto</i>	<i>Descripción recibida en el CSV.</i>

Esta tabla conserva la estructura base sin PK, FK ni restricciones UNIQUE. temporal sirve para la carga inicial; tamaño es independiente de las consultas de ventas.

tamanio*Estructura de tamanio*

<i>Campo</i>	<i>Tipo y tamaño</i>	<i>NULL / defecto</i>	<i>Claves y valores</i>
<i>id_registro</i>	<i>integer / 4 B</i>	<i>No / Sin valor por defecto</i>	<i>Consecutivo 1 a N generado; sin PK declarada.</i>
<i>id_departamento</i>	<i>integer / 4 B</i>	<i>No / Sin valor por defecto</i>	<i>Código tomado del catálogo; sin FK declarada.</i>
<i>id_municipio</i>	<i>integer / 4 B</i>	<i>No / Sin valor por defecto</i>	<i>Municipio elegido al azar; sin FK declarada.</i>
<i>id_producto</i>	<i>integer / 4 B</i>	<i>No / Sin valor por defecto</i>	<i>Entero aleatorio de 1 a 4.</i>
<i>fecha</i>	<i>varchar(10)</i>	<i>Sí / Sin valor por defecto</i>	<i>Texto DD-MM-2023; día 1–28 y mes 1–12.</i>
<i>cantidad</i>	<i>integer / 4 B</i>	<i>Sí / 0</i>	<i>Entero aleatorio de 1 a 5.000.</i>
<i>estado</i>	<i>varchar(1)</i>	<i>Sí / Sin valor por defecto</i>	<i>'F' durante la prueba.</i>

Esta tabla conserva la estructura base sin PK, FK ni restricciones UNIQUE. temporal sirve para la carga inicial; tamanio es independiente de las consultas de ventas.


4 Corrida del algoritmo ETL

Conservamos `getCodigoRegion`, `cargarTablaTemporal`, `cargarDepartamento` y `cargarMunicipio`. Cambiamos el lector para usar las comillas propias de CSV y reparamos las dos filas que venían encerradas en comillas completas. Así se cargaron también Providencia y San Andrés. Los originales permanecen separados de los resultados.

El programa conecta a una base vacía, crea las tablas y carga 1.123 filas en temporal. Después registra 6 regiones, 33 entradas departamentales y 1.123 municipios. Las 33 entradas corresponden a los departamentos y Bogotá D. C. Los identificadores internos se construyen con el prefijo 57 y el consecutivo municipal del programa base. Dejamos explícito el orden C para reproducir esa numeración y comprobamos que Támesis tiene el ID 5705108.

A continuación se cargan las 10.000 ventas y se exporta una copia anterior a la limpieza. Las transformaciones y comprobaciones se ejecutan dentro de una transacción. Si ocurre un error, se revierte la carga. Cuando la vista y la tabla conservan 10.000 registros, se exportan las consultas y se confirma la transacción. La corrida ETL medida tomó 974,164 ms, sin incluir las pruebas posteriores de tamaño.

```
(.venv) PS C:\Users\User\Downloads\bigdata-et0155-tarea-ETL-v2-entrega\Unidad_1_ETL\python> python
n c:\Users\User\Downloads\bigdata-et0155-tarea-ETL-v2-entrega\Unidad_1_ETL\python\algoritmo-etl.p
y
ENTORNO: ('PostgreSQL 18.0 on x86_64-windows, compiled by msvc-19.44.35217, 64-bit', 'bigdata')
CSV: 1123 filas; comillas reparadas en líneas [917, 950]
CARGA: 6 regiones, 33 departamentos, 1123 municipios y 10000 operaciones.
CONTROL: operaciones = 10000; vista = 10000; modificados = 30; válidos sin cambios = 9970.
ETL CONFIRMADO. Duración total ms: 644.276
(.venv) PS C:\Users\User\Downloads\bigdata-et0155-tarea-ETL-v2-entrega\Unidad_1_ETL\python>
```



5 Incorporación de la región

Creamos regiones con `id_region` como clave primaria y `nombre` como valor único. Agregamos `id_region` a operaciones y lo completamos después de corregir los departamentos faltantes. La actualización una operaciones con departamentos y copia `codigo_region`.

Query		Query History
1	<code>SELECT o.id_registro, o.id_region, r.nombre AS region</code>	
2	<code>FROM operaciones o</code>	
3	<code>LEFT JOIN regiones r ON o.id_region = r.id_region</code>	
4	<code>ORDER BY o.id_registro</code>	
5	<code>LIMIT 20;</code>	

Data Output		Messages	Notifications
Showing rows: 1 to 20			
	<code>id_registro</code> integer	<code>id_region</code> integer	<code>region</code> character varying (70)
1	10001	4	Region Caribe
2	10002	2	Region Centro Oriente
3	10003	6	Region Pacifico
4	10004	4	Region Caribe
5	10005	6	Region Pacifico

Catálogo de regiones

Código	Región
1	Region Eje Cafetero - Antioquia
2	Region Centro Oriente
3	Region Centro Sur
4	Region Caribe
5	Region Llano
6	Region Pacifico

6 Detección y corrección de registros

Encontramos 10 fechas con formato irregular, 5 cantidades en cero, 5 cantidades negativas, 5 departamentos faltantes y 5 productos faltantes. Son 30 registros distintos, equivalentes al 0,30 % del conjunto. No eliminamos ventas, porque en estos casos había información suficiente para aplicar las reglas de la actividad.

Primero convertimos las cantidades negativas a positivas. Luego calculamos el promedio de cantidades de cada municipio usando solamente cantidades positivas, sin incluir los ceros. Los dos ceros de un mismo municipio reciben el mismo promedio original. Redondeamos al entero más cercano porque una unidad de gaseosa no se registra como fracción. AVG y SUM se aplican como funciones de agregación sobre los registros seleccionados (PostgreSQL Global Development Group, s. f.-a).

Para las fechas cortas utilizamos 2024, que es el año del conjunto. El registro 16558 requiere una decisión explícita: interpretamos 01-02-24 como 1 de febrero de 2024, siguiendo DD-MM-AA. El texto también permite una lectura como 2 de enero; el archivo no permite resolverla por sí solo. La causa conserva esta incertidumbre. Ninguna de las seis consultas agrupa por fecha, por lo que esta elección no cambia sus resultados.

```
(.venv) PS C:\Users\User\Downloads\bigdata-et0155-tarea-ETL-v2-entrega\Unidad_1_ETL\python> py
● thon algoritmo-etl.py
ENTORNO: ('PostgreSQL 18.0 on x86_64-windows, compiled by msvc-19.44.35217, 64-bit', 'bigdata'
)
CSV: 1123 filas; comillas reparadas en líneas [917, 950]
CARGA: operaciones originales = 10000
EXPLORACIÓN INICIAL:
tipo                                problema  registros
A Fecha fuera del formato AAAA-MM-DD o inexistente      10
B                                Cantidad en cero o ausente      5
C                                Cantidad negativa      5
D                                Código de departamento ausente      5
E                                Código de producto ausente      5
Registros distintos con problemas: 30
Traceback (most recent call last):
```

Detalle de los 30 registros corregidos

Tipo	Registro	Campo	Valor original	Corrección y criterio
A	10001	fecha	2024-8-21	fecha 2024-8-21 -> 2024-08-21. Completar mes con cero.
C	10014	cantidad	-198	cantidad -198 -> 198; retirar signo negativo.
B	10225	cantidad	0	cantidad 0 -> 136; promedio municipal 136.000000 de 7 registros con cantidad positiva; redondeo a unidad.
D	10326	id_departamento	0	departamento 0 -> 5715; recuperado del municipio Maripi.
E	10686	id_producto	0	producto 0 -> 4 NARANJITA; regla del caso para Tamesis, Antioquia.
A	11599	fecha	24-02-08	fecha 24-02-08 -> 2024-02-08. Interpretación AA-MM-DD y año 2024.
E	11734	id_producto	0	producto 0 -> 4 NARANJITA; regla del caso para Tamesis, Antioquia.
C	11907	cantidad	-144	cantidad -144 -> 144; retirar signo negativo.
A	12110	fecha	024-07-17	fecha 024-07-17 -> 2024-07-17. Completar año truncado 024 como 2024.
D	12188	id_departamento	0	departamento 0 -> 5715; recuperado del municipio Ventaquemada.
B	13161	cantidad	0	cantidad 0 -> 105; promedio municipal 104.916667 de 12 registros con cantidad positiva; redondeo a unidad.
A	13945	fecha	13-12-2024	fecha 13-12-2024 -> 2024-12-13. Interpretación DD-MM-AAAA.
D	14020	id_departamento	0	departamento 0 -> 5723; recuperado del municipio San Pelayo.
A	14368	fecha	24-28-10	fecha 24-28-10 -> 2024-10-28. Interpretación AA-DD-MM y año 2024.
C	15208	cantidad	-175	cantidad -175 -> 175; retirar signo negativo.
B	15412	cantidad	0	cantidad 0 -> 79; promedio municipal 79.200000 de 5 registros con cantidad positiva; redondeo a unidad.
A	15955	fecha	24-27-09	fecha 24-27-09 -> 2024-09-27. Interpretación AA-DD-MM y año 2024.
A	16558	fecha	01-02-24	fecha 01-02-24 -> 2024-02-01. Supuesto DD-MM-AA; no se puede descartar 2024-01-02 con el dato original.
D	16635	id_departamento	0	departamento 0 -> 5741; recuperado del municipio Neiva.
A	17125	fecha	12-12-2024	fecha 12-12-2024 -> 2024-12-12. Interpretación DD-MM-AAAA.
E	17341	id_producto	0	producto 0 -> 4 NARANJITA; regla del caso para Tamesis, Antioquia.
B	17528	cantidad	0	cantidad 0 -> 79; promedio municipal 79.200000 de 5 registros con cantidad positiva; redondeo a unidad.

A	18056	fecha	24-09-09	fecha 24-09-09 -> 2024-09-09. Interpretación AA-MM-DD y año 2024.
C	18126	cantidad	-181	cantidad -181 -> 181; retirar signo negativo.
D	18469	id_departamento	0	departamento 0 -> 5763; recuperado del municipio Quimbaya.
E	18911	id_producto	0	producto 0 -> 4 NARANJITA; regla del caso para Tamesis, Antioquia.
B	19181	cantidad	0	cantidad 0 -> 107; promedio municipal 107.181818 de 11 registros con cantidad positiva; redondeo a unidad.
E	19195	id_producto	0	producto 0 -> 4 NARANJITA; regla del caso para Tamesis, Antioquia.
C	19538	cantidad	-112	cantidad -112 -> 112; retirar signo negativo.
A	19680	fecha	11-23-2024	fecha 11-23-2024 -> 2024-11-23. Interpretación MM-DD-AAAA.

Imputación de cantidades en cero

Registro	Municipio	Promedio positivo	Cantidad imputada
10225	Apulo	136,000000	136
13161	Angostura	104,916667	105
15412	Sotara	79,200000	79
17528	Sotara	79,200000	79
19181	Sachica	107,181818	107

Detección de los campos con conflicto

```
(.venv) PS C:\Users\User\Downloads\bigdata-et0155-tarea-ETL-v2-entrega\Unidad_1_ETL\python> python algoritmo-etl.py
ENTORNO: ('PostgreSQL 18.0 on x86_64-windows, compiled by msvc-19.44.35217, 64-bit', 'bigdata')
CSV: 1123 filas; comillas reparadas en líneas [917, 950]
CARGA: operaciones originales = 10000
EXPLORACIÓN INICIAL:
tipo                problema  registros
A Fecha fuera del formato AAAA-MM-DD o inexistente      10
B                Cantidad en cero o ausente              5
C                Cantidad negativa                      5
D                Código de departamento ausente         5
E                Código de producto ausente             5
Registros distintos con problemas: 30
CONTROL: operaciones = 10000; vista = 10000; modificados = 30; válidos sin cambios = 9970.
CONFIRMADO. Duración total ms: 381.344
```


Solución de los campos con conflicto

```
(.venv) PS C:\Users\User\Downloads\bigdata-et0155-tarea-ETL-v2-entrega\Unidad_1_ETL
L\python> python aplicar-limpieza.py
```

17341	2024-03-17	132	5705	4 modificado
17528	2024-11-02	79	5719	3 modificado
18056	2024-09-09	86	5785	1 modificado
18126	2024-02-13	181	5720	2 modificado
18469	2024-06-20	2	5763	4 modificado
18911	2024-03-23	126	5705	4 modificado
19181	2024-12-08	107	5715	4 modificado
19195	2024-03-15	126	5705	4 modificado
19538	2024-08-23	112	5754	1 modificado
19680	2024-11-23	129	5705	4 modificado

```

PROBLEMAS RESTANTES
tipo                problema  registros
A Fecha fuera del formato AAAA-MM-DD o inexistente      0
B                      Cantidad en cero o ausente      0
C                      Cantidad negativa                0
D                      Código de departamento ausente  0
E                      Código de producto ausente      0
Filas conservadas: 10000.
(.venv) PS C:\Users\User\Downloads\bigdata-et0155-tarea-ETL-v2-entrega\Unidad_1_ETL
L\python>

```

7 Consultas SQL

Las seis consultas usan exclusivamente vista_operaciones. venta se calcula como cantidad × precio. Ordenamos también por nombre cuando hay empate, para que la selección pueda repetirse. Antes de obtener los resultados comprobamos 10.000 filas tanto en operaciones como en la vista, sin duplicados de id_registro. Además, verificamos que los seis resultados coinciden con los obtenidos mediante uniones directas de las tablas.

Consulta 7.1


Consulta

7.1

Ocho departamentos con
mayor monto

SQL

```
SELECT departamento, SUM(venta) AS monto_total  
FROM vista_operaciones  
GROUP BY departamento  
ORDER BY monto_total DESC, departamento ASC  
LIMIT 8;
```



```
1 SELECT departamento, SUM(venta) AS monto_total
2 FROM vista_operaciones
3 GROUP BY departamento
4 ORDER BY monto_total DESC, departamento ASC
5 LIMIT 8;
6
```

	departamento character varying (70)	monto_total numeric
1	Antioquia	105759800
2	Boyaca	99513900
3	Cundinamarca	8349300
4	Santander	73633600
5	Nariño	54167600
6	Bolivar	40279200
7	Tolima	39817700
8	Valle del Cauca	36605600

Consulta 7.2

Consulta

7.2
Quince municipios de
Antioquia con más
unidades

SQL

```
SELECT municipio, SUM(cantidad) AS cantidad_total
FROM vista_operaciones
WHERE id_departamento=5705
GROUP BY id_municipio, municipio
ORDER BY cantidad_total DESC, municipio ASC
LIMIT 15;
```

Query		Query History
1	SELECT municipio, SUM(cantidad) AS cantidad_total	
2	FROM vista_operaciones	
3	WHERE id_departamento=5705	
4	GROUP BY id_municipio, municipio	
5	ORDER BY cantidad_total DESC, municipio ASC	
6	LIMIT 15;	
Data Output		Messages Notifications
	municipio character varying (70)	cantidad_total bigint
1	Valdivia	1850
2	Turbo	1708
3	Sopetran	1699
4	Nariño	1611
5	Caicedo	1604
6	Amaga	1600



Consulta 7.3

Consulta

7.3

Cinco departamentos con
más MANZALOCA

SQL

```
SELECT departamento, SUM(cantidad) AS cantidad_total
FROM vista_operaciones
WHERE producto='MANZALOCA'
GROUP BY departamento
ORDER BY cantidad_total DESC, departamento ASC
LIMIT 5;
```

Dashboard x bigdata/postgres@PostgreSQL 18* x

bigdata/postgres@PostgreSQL 18

Query Query History

```
1 SELECT departamento, SUM(cantidad) AS cantidad_total
2 FROM vista_operaciones
3 WHERE producto='MANZALOCA'
4 GROUP BY departamento
5 ORDER BY cantidad_total DESC, departamento ASC
6 LIMIT 5;
```

Data Output Messages Notifications

	departamento character varying (70)	cantidad_total bigint
1	Antioquia	27305
2	Boyaca	26577
3	Cundinamarca	25510
4	Santander	21376
5	Nariño	14273

Consulta 7.4

Consulta

7.4

Cinco municipios con
menor monto

SQL

```
SELECT departamento, municipio, SUM(venta) AS monto_total
FROM vista_operaciones
GROUP BY id_municipio, departamento, municipio
ORDER BY monto_total ASC, departamento ASC, municipio ASC
LIMIT 5;
```

```
1 SELECT departamento, municipio, SUM(venta) AS monto_total
2 FROM vista_operaciones
3 GROUP BY id_municipio, departamento, municipio
4 ORDER BY monto_total ASC, departamento ASC, municipio ASC
5 LIMIT 5;
6
```

Data Output Messages Notifications

	departamento character varying (70)	municipio character varying (70)	monto_total numeric
1	Valle del Cauca	Zarzal	68200
2	Cesar	Pelaya	86400
3	Boyaca	Togñi	92800
4	Cordoba	Momil	94200
5	Cundinamarca	Sesquile	104200

Consulta 7.5

Consulta

7.5

Unidades por producto y
región

SQL

```
SELECT region, producto, SUM(cantidad) AS cantidad_total
FROM vista_operaciones
GROUP BY id_region, region, producto
ORDER BY cantidad_total DESC, region ASC, producto ASC;
```

1	SELECT	region, producto, SUM(cantidad) AS cantidad_total
2	FROM	vista_operaciones
3	GROUP BY	id_region, region, producto
4	ORDER BY	cantidad_total DESC, region ASC, producto ASC;
5		

	region character varying (70)	producto character varying (20)	cantidad_total bigint
1	Region Centro Oriente	MANGOSON	83105
2	Region Centro Oriente	MANZALOCA	82590
3	Region Centro Oriente	NARANJITA	82514
4	Region Centro Oriente	COLOMBIANITA	78059
5	Region Caribe	NARANJITA	47274
6	Region Caribe	COLOMBIANITA	44702
7	Region Caribe	MANGOSON	44699
8	Region Pacifico	MANGOSON	43859
9	Region Pacifico	COLOMBIANITA	42949

Consulta 7.6

Consulta

7.6

Monto por producto en
Antioquia

SQL

```
SELECT producto, SUM(venta) AS monto_total
FROM vista_operaciones
WHERE id_departamento=5705
GROUP BY producto
ORDER BY monto_total DESC, producto ASC;
```

Query		Query History
1	SELECT	producto, SUM(venta) AS monto_total
2	FROM	vista_operaciones
3	WHERE	id_departamento=5705
4	GROUP BY	producto
5	ORDER BY	monto_total DESC, producto ASC;
6		

Data Output		Messages	Notifications
≡+ 📄 ▼ 📋 ▼ 🗑️ 🗄️ ⬇️ 📈 SQL			
	producto character varying (20) 🔒	monto_total numeric 🔒	
1	COLOMBIANITA	35680800	
2	MANZALOCA	27305000	
3	MANGOSON	24820200	
4	NARANJITA	17953800	

8 Resultados y gráficos

Los gráficos de Pareto ordenan las categorías de mayor a menor y permiten reconocer cuáles concentran el monto o las unidades. La ASQ (s. f.) describe las barras ordenadas como su base y presenta el porcentaje acumulado como un complemento. En el libro se muestran barras y curva en dos paneles editables de la misma pestaña. El acumulado se calcula sobre el subtotal de las categorías seleccionadas, no sobre todo el país.


En 8.1 usamos COP, porque la consulta 7.1 pide monto. La plantilla menciona cantidades en ese eje, pero cambiar la unidad haría que el gráfico dejara de representar la consulta. En 8.4 conservamos el CSV ascendente solicitado y reordenamos solo sus cinco resultados para dibujar el Pareto. En las tortas no hay ejes cartesianos; los productos se identifican con la leyenda y los valores se muestran junto a la figura.

8 1 Ocho departamentos con mayor monto

Resultados de la consulta 7.1

Departamento	Monto COP
Antioquia	105.759.800
Boyaca	99.513.900
Cundinamarca	93.349.300
Santander	73.633.600
Nariño	54.167.600
Bolivar	40.279.200
Tolima	39.817.700
Valle del Cauca	36.605.600

Pareto de ocho departamentos con mayor monto



Participación acumulada de las categorías seleccionadas


Ventas por departamento ▾					
Departamento ▾	Monto total (COP) ▾	%	% del total ▾	%	% acumulado ▾
Antioquia	\$105,759,800.00		19.47%		19.47%
Boyacá	\$99,513,900.00		18.32%		37.79%
Cundinamarca	\$93,349,300.00		17.19%		54.98%
Santander	\$73,633,600.00		13.56%		68.54%
Nariño	\$54,167,600.00		9.97%		78.51%
Bolívar	\$40,279,200.00		7.42%		85.93%
Tolima	\$39,817,700.00		7.33%		93.26%
Valle del Cauca	\$36,605,600.00		6.74%		100.00%
Total	\$543,126,700.00		100.00%		

8 2 Quince municipios de Antioquia con más unidades

Resultados de la consulta 7.2

Municipio	Unidades
Valdivia	1.850
Turbo	1.708
Sopetran	1.699
Nariño	1.611
Caicedo	1.604
Amaga	1.600
Frontino	1.520
Puerto Berrio	1.514
Anori	1.510
Dabeiba	1.441
Amalfi	1.430
Belmira	1.412
San Pedro de Uraba	1.399
Venecia	1.391
Arboletes	1.380

Pareto de quince municipios de Antioquia con más unidades



Participación acumulada de las categorías seleccionadas


Municipio	Cantidad total (unidades)	% del total	% acumulado
Valdivia	1,850	8.0%	8.02%
Turbo	1,708	7.4%	15.42%
Sopetran	1,699	7.4%	22.79%
Nariño	1,611	7.0%	29.77%
Caicedo	1,604	7.0%	36.72%
Amaga	1,600	6.9%	43.66%
Frontino	1,520	6.6%	50.25%
Puerto Berrio	1,514	6.6%	56.81%
Anori	1,510	6.5%	63.36%
Dabeiba	1,441	6.2%	69.60%
Amalfi	1,430	6.2%	75.80%
Belmira	1,412	6.1%	81.92%
San Pedro de Uraba	1,399	6.1%	87.99%
Venecia	1,391	6.0%	94.02%
Arboletes	1,380	6.0%	100.00%
TOTAL	23,069	100.0%	

8.3 Cinco departamentos con más MANZALOCA

Resultados de la consulta 7.3

Departamento	Unidades
Antioquia	27.305
Boyaca	26.577
Cundinamarca	25.510
Santander	21.376
Nariño	14.273

Pareto de cinco departamentos con más manzaloca



Participación acumulada de las categorías seleccionadas


Departamento	Cantidad total un	% Acumulado
Antioquia	27,305	23.74%
Boyaca	26,577	46.84%
Cundinamarca	25,510	69.01%
Santander	21,376	87.59%
Nariño	14,273	100.00%
Total	115,041	

8 4 Cinco municipios con menor monto

Resultados de la consulta 7.4

<i>Departamento</i>	<i>Municipio</i>	<i>Monto COP</i>
Valle del Cauca	Zarzal	68.200
Cesar	Pelaya	86.400
Boyaca	Togñi	92.800
Cordoba	Momil	94.200
Cundinamarca	Sesquile	104.200

Pareto de cinco municipios con menor monto



Participación acumulada de las categorías seleccionadas

Municipio (Departamento)	Monto total	% Acumulado
Sesquile (Cundinamarca)	\$104,200	23.4%
Momil (Cordoba)	\$94,200	44.5%
Togñi (Boyaca)	\$92,800	65.3%
Pelaya (Cesar)	\$86,400	84.7%

Zarzal (Valle del Cauca)	\$68,200	100.0%
TOTAL	\$445,800.00	


8 5 Unidades por producto y región

Resultados de la consulta 7.5


Región	Producto	Unidades
<i>Region Centro Oriente</i>	<i>MANGOSON</i>	<i>83.105</i>
<i>Region Centro Oriente</i>	<i>MANZALOCA</i>	<i>82.590</i>
<i>Region Centro Oriente</i>	<i>NARANJITA</i>	<i>82.514</i>
<i>Region Centro Oriente</i>	<i>COLOMBIANITA</i>	<i>78.059</i>
<i>Region Caribe</i>	<i>NARANJITA</i>	<i>47.274</i>
<i>Region Caribe</i>	<i>COLOMBIANITA</i>	<i>44.702</i>
<i>Region Caribe</i>	<i>MANGOSON</i>	<i>44.699</i>
<i>Region Pacifico</i>	<i>MANGOSON</i>	<i>43.859</i>
<i>Region Pacifico</i>	<i>COLOMBIANITA</i>	<i>42.949</i>
<i>Region Caribe</i>	<i>MANZALOCA</i>	<i>42.727</i>
<i>Region Eje Cafetero - Antioquia</i>	<i>COLOMBIANITA</i>	<i>41.966</i>
<i>Region Eje Cafetero - Antioquia</i>	<i>NARANJITA</i>	<i>41.405</i>
<i>Region Pacifico</i>	<i>NARANJITA</i>	<i>39.984</i>
<i>Region Pacifico</i>	<i>MANZALOCA</i>	<i>39.871</i>
<i>Region Eje Cafetero - Antioquia</i>	<i>MANGOSON</i>	<i>39.231</i>
<i>Region Eje Cafetero - Antioquia</i>	<i>MANZALOCA</i>	<i>38.089</i>
<i>Region Centro Sur</i>	<i>NARANJITA</i>	<i>29.775</i>
<i>Region Centro Sur</i>	<i>MANZALOCA</i>	<i>28.327</i>
<i>Region Centro Sur</i>	<i>MANGOSON</i>	<i>28.248</i>
<i>Region Centro Sur</i>	<i>COLOMBIANITA</i>	<i>27.858</i>
<i>Region Llano</i>	<i>MANZALOCA</i>	<i>16.444</i>
<i>Region Llano</i>	<i>NARANJITA</i>	<i>15.595</i>
<i>Region Llano</i>	<i>COLOMBIANITA</i>	<i>14.430</i>
<i>Region Llano</i>	<i>MANGOSON</i>	<i>14.054</i>

Composición por producto en centro oriente

Region Centro Oriente


*Composición por producto en caribe*

Región Caribe




Composición por producto en Pacífico

Región Pacífico


*Composición por producto en Eje Cafetero - Antioquia*

Región Eje Cafetero - Antioquia




Composición por producto en Centro Sur

Región Centro Sur



Composición por producto en Llano

Región Llano



8 6 Monto por producto en Antioquia


Resultados de la consulta 7.6

Producto	Monto COP
COLOMBIANITA	35.680.800
MANZALOCA	27.305.000
MANGOSON	24.820.200
NARANJITA	17.953.800

Participación del monto vendido por producto en Antioquia

Producto	Monto total	%
COLOMBIANITA	\$35,680,800	33.7%
MANZALOCA	\$27,305,000	25.8%
MANGOSON	\$24,820,200	23.5%
NARANJITA	\$17,953,800	17.0%
TOTAL	\$105,759,800.00	

Monto de venta por cada producto en Antioquia



10 Tiempo y tamaño de procesamiento

Modificamos `algoritmo-calculo-tamano.py` para medir desde el inicio de la generación hasta la confirmación del último registro. Se conserva la selección aleatoria de producto, cantidad, fecha de 2023 y municipio. Para ejecutar diez millones de registros sin hacer una consulta y una confirmación por cada fila, leemos una vez el catálogo municipal e insertamos lotes de 10.000 filas. La misma estrategia se usa en las cuatro pruebas.

Antes de cada corrida se vacía únicamente `tamano`. Se utiliza la semilla 20260923 y se confirma que la cantidad almacenada coincida con la solicitada. La tabla conserva su estructura original, sin índices adicionales. Los resultados son mediciones de una corrida por tamaño, no promedios ni estimaciones.

```
(.venv) PS C:\Users\User\Downloads\bigdata-et0155-tarea-ETL-v2-entrega\Unidad_1_ETL\python> python algoritmo-calculo-tamano.py
--registros 10000 100000 1000000 10000000
{"registros": 10000, "tiempo_ms": 100.11, "tabla_bytes": 712704, "bd_bytes": 11425471, "tabla_kib": 696.0, "bd_mib": 10.8961782
45544434, "porcentaje": 6.237852251342636}
{"registros": 100000, "tiempo_ms": 909.241, "tabla_bytes": 6856704, "bd_bytes": 17569471, "tabla_kib": 6696.0, "bd_mib": 16.755
553245544434, "porcentaje": 39.026240459943274}
{"registros": 1000000, "tiempo_ms": 9997.621, "tabla_bytes": 68321280, "bd_bytes": 79034047, "tabla_kib": 66720.0, "bd_mib": 75
.37274074554443, "porcentaje": 86.44537714233462}
{"registros": 10000000, "tiempo_ms": 109035.12, "tabla_bytes": 682876928, "bd_bytes": 693589695, "tabla_kib": 666872.0, "bd_mib
": 661.4586782455444, "porcentaje": 98.45546047220324}
(.venv) PS C:\Users\User\Downloads\bigdata-et0155-tarea-ETL-v2-entrega\Unidad_1_ETL\python>
```

Resultados medidos de procesamiento y almacenamiento

Registros	Tiempo ms	Tabla KiB	Base MiB	Tabla / base
10.000	100,110	696,00	10,90	6,24 %
100.000	909,241	6.696,00	16,76	39,03 %
1.000.000	9.997,621	66.720,00	75,37	86,45 %
10.000.000	109.035,120	666.872,00	661,46	98,46 %

El tiempo de procesamiento pasó de 100,110 ms para 10.000 registros a 109.035,120 ms para 10.000.000 de registros. El crecimiento fue aproximadamente proporcional dentro de este experimento. Con diez millones de registros, la tabla tamaño ocupa 651,24 MiB y representa el 98,46 % del tamaño de la base de datos. Por su volumen, conviene mantener estos datos de prueba separados del análisis de ventas. Las mediciones incluyen la generación de registros, su

inserción y la confirmación de la transacción, por lo que no representan únicamente la velocidad de escritura del motor.

11 Análisis de los resultados

Al revisar el monto vendido por departamento, Antioquia aparece en primer lugar con COP 105.759.800, cifra que corresponde al 11,37 % del total. Después se encuentran Boyacá y Cundinamarca. En conjunto, los ocho primeros departamentos reúnen COP 543.126.700, equivalentes al 58,41 % del monto nacional registrado en el archivo. Debido a esta concentración, proponemos comenzar por revisar la disponibilidad de inventario y la frecuencia de las entregas en esos departamentos.

Sin embargo, el primer lugar de Antioquia no demuestra por sí solo que allí exista una mayor preferencia por las gaseosas. Antioquia cuenta con 1.108 registros, mientras que Boyacá tiene 1.060 y Cundinamarca 1.023. Esto muestra que la cantidad de operaciones también influye en el monto final. Para hacer una comparación más completa, revisaríamos las ventas por punto de distribución y la cobertura de los registros. El archivo no contiene esta información y los campos de población aparecen en cero, por lo que no sería correcto explicar las diferencias a partir del número de habitantes.

Dentro de Antioquia, Valdivia ocupa el primer lugar de la consulta 7.2 con 1.850 unidades. Le siguen Turbo, con 1.708, y Sopetrán, con 1.699. Estos resultados sirven como punto de partida para revisar el inventario disponible en los tres municipios. Aun así, antes de

aumentar las compras de manera permanente habría que comprobar si ese comportamiento se mantiene durante el año o si las ventas se concentran en unas pocas operaciones.

En el caso de MANZALOCA, Antioquia registra 27.305 unidades, Boyacá 26.577 y Cundinamarca 25.510. Estas cifras permiten dar prioridad al seguimiento del producto en esos departamentos. Lo que no permiten es afirmar que MANZALOCA tenga más aceptación que todos sus competidores, ya que el caso únicamente incluye las cuatro referencias de Gaseosas Poderosas.

En el extremo contrario se encuentra Zarzal, con el menor monto registrado: COP 68.200. Después aparece Pelaya con COP 86.400. Zarzal cuenta con dos transacciones, mientras que Pelaya tiene una; Momil también aparece con una sola transacción. Antes de interpretar estos montos como un problema de distribución o como una demanda baja, proponemos comprobar si el registro de las ventas está completo, si hubo entregas durante todo el periodo y si existen puntos activos en cada municipio. Providencia y San Andrés figuran en el catálogo, pero no presentan operaciones en la fuente. La ausencia de registros no significa que las ventas hayan sido iguales a cero.

Al agrupar la información por regiones, Centro Oriente alcanza 326.268 unidades y presenta el mayor volumen del archivo. Allí, MANGOSON registra 83.105 unidades y MANZALOCA 82.590, una diferencia pequeña frente al total de la región. En Caribe, NARANJITA ocupa el primer lugar con 47.274 unidades. Utilizar un gráfico de torta para cada


región permite observar su mezcla de productos sin combinar categorías que pertenecen a grupos diferentes.


En Antioquia, COLOMBIANITA presenta el mayor monto, con COP 35.680.800. No obstante, su precio unitario es más alto que el de las demás referencias, por lo que ese monto no debe interpretarse como si representara automáticamente una mayor cantidad de unidades. Antes de modificar el inventario de cada producto, recomendamos revisar las dos medidas: cantidad y monto vendido.


12 Diagrama de flujo del programa ETL

Hicimos el diagrama de flujo con pseudocódigo en PSeint

Diagrama de flujo del ETL







Pseudocódigo

Algoritmo ETL

Definir paso **Como Cadena**

Definir conexionCorrecta, cargaNecesaria, filaCorrecta **Como Lógico**

Definir datosPendientes, controlCorrecto **Como Lógico**

Definir filasCSV, fila, departamentos, municipios **Como Entero**

Definir registrosAntes, registrosDespues, registrosVista **Como Entero**

Definir consulta **Como Entero**

paso ← 'Leer configuracion, rutas y criterio para fechas ambiguas'

paso ← 'Abrir conexion con PostgreSQL'

Leer conexionCorrecta

Si conexionCorrecta **Entonces**

 paso ← 'Iniciar transaccion y revisar estructura y datos existentes'

 Leer cargaNecesaria

Si cargaNecesaria **Entonces**

 paso ← 'Preparar las tablas necesarias para la carga inicial'

 paso ← 'Abrir CSV del DANE y omitir encabezado'

 Leer filasCSV

Para fila←1 **Hasta** filasCSV **Hacer**

 paso ← 'Leer region, departamento, municipio y codigos DANE'

 Leer filaCorrecta

Si NO filaCorrecta **Entonces**

 paso ← 'Reinterpretar la fila con comillas externas y validar sus cinco campos'

FinSi

 paso ← 'Relacionar el nombre de region con su codigo'

 paso ← 'Insertar fila en temporal'

FinPara

 paso ← 'Cargar catalogo de regiones'

 paso ← 'Agrupar departamentos de la tabla temporal'

 Leer departamentos

Para fila←1 **Hasta** departamentos **Hacer**

```

Para fila←1 Hasta departamentos Hacer
|   paso ← 'Construir codigo entero del departamento e insertar sus datos'
FinPara
paso ← 'Ordenar municipios por departamento y nombre'
Leer municipios
Para fila←1 Hasta municipios Hacer
|   paso ← 'Numerar municipio dentro de su departamento y construir su codigo'
|   paso ← 'Insertar municipio y conservar codigo DANE'
FinPara
paso ← 'Validar correspondencia de codigos municipales con las ventas'
paso ← 'Cargar operaciones del archivo SQL original'
SiNo
|   paso ← 'Usar operaciones y catalogos existentes sin duplicar la carga'
FinSi
paso ← 'Leer operaciones y conservar copia previa a la limpieza'
Leer registrosAntes
paso ← 'Crear DataFrame y detectar problemas A, B, C, D y E'
paso ← 'Mostrar resumen inicial y numero de registros afectados'
paso ← 'Aplicar limpieza detallada en el diagrama 02'
paso ← 'Exportar diagnostico, correcciones y casos pendientes'
Leer datosPendientes
Si datosPendientes Entonces
|   paso ← 'Revisar casos pendientes antes de confirmar las correcciones'
|   paso ← 'Revertir transaccion'
SiNo
|   paso ← 'Guardar correcciones, validacion y causa en operaciones'
|   paso ← 'Asignar id_region desde el departamento'
|   paso ← 'Crear o actualizar vista_operaciones'
|   paso ← 'Contar operaciones y filas de la vista'

```

```

Leer registrosDespues, registrosVista
controlCorrecto ← registrosAntes=registrosDespues Y registrosDespues=registrosVista
Si controlCorrecto Entonces
    paso ← 'Exportar operaciones limpias y auditoria'
    Para consulta←1 Hasta 6 Hacer
        paso ← 'Ejecutar consulta 7 sobre vista_operaciones y exportar resultados'
    FinPara
    paso ← 'Exportar catalogos y resumen de ventas'
    paso ← 'Confirmar transaccion'
    Escribir 'Mostrar conteos y duracion del ETL'
SiNo
    paso ← 'Revertir transaccion y revisar registros o relaciones faltantes'
FinSi
FinSi
paso ← 'Cerrar conexion'
SiNo
    Escribir 'Informar error de conexion'
FinSi
FinAlgoritmo

```

13 Conclusiones

Conclusiones Santiago Restrepo Torres

Este trabajo me ayudó a entender mejor que la extracción, la transformación y la carga forman parte de un mismo proceso. Al llevar la información a PostgreSQL no basta con importarla. También hay que revisar cómo está organizada, ordenar los códigos y comprobar que las relaciones entre las tablas funcionen como se espera.

Una de las lecciones más importantes para mi formación como desarrollador fue reconocer que un programa puede ejecutarse sin mostrar errores y, aun así, entregar información incompleta. Por esta razón, considero importante revisar el resultado de cada etapa antes de avanzar con el análisis.

La limpieza de datos me mostró que un registro con errores no siempre debe eliminarse. En esta actividad fue posible corregir fechas, convertir cantidades negativas e imputar valores faltantes utilizando información del municipio y las reglas del caso. También comprendí que cada modificación necesita una justificación, especialmente cuando un dato admite varias interpretaciones. Este aprendizaje me sirve para trabajar con información real, donde debo conservar los datos útiles y dejar constancia de las decisiones tomadas.

Al analizar las consultas comprendí que obtener un total de ventas es apenas el comienzo de la interpretación. Que un departamento registre un monto mayor no demuestra por sí solo que tenga más demanda o que sea más rentable. También influyen la cantidad de operaciones registradas y la cobertura de la información disponible. Para mi formación profesional, esta

actividad refuerza la importancia de diferenciar lo que los datos muestran de las explicaciones que todavía necesitan comprobarse antes de recomendar una decisión.

Conclusiones Estiven Cano Rendon

Este trabajo me ayudó a entender mejor que la extracción, la transformación y la carga forman parte de un proceso necesario para mostrar los datos necesarios para la toma de decisiones en un entorno corporativo. Los datos solo serán un recurso valioso solo si tienen coherencia e integridad.

Cometí un error al ejecutar dos veces el script de carga, la tabla de operaciones quedó con 20.000 registros en lugar de 10.000. Como la tabla no tenía clave primaria, la base de datos aceptó los duplicados sin advertir nada. Esto me enseñó el valor de las restricciones de integridad y de verificar cada paso con un conteo antes de avanzar. También comprobé que la vista vista_operaciones solo es confiable cuando devuelve el mismo número de registros que la tabla, porque esa igualdad demuestra que no hay relaciones rotas.

El trabajo me ayudó a comprender la importancia de ETL ya que no se trata solo de obtener datos, es saber cómo trabajar con ellos, cuáles están mal y limpiarlos, para luego cargarlos y hacer un análisis que ayude a tomar decisiones en el negocio.

conclusiones Angi K. Ruiz

Al revisar los resultados de las consultas comprendí que un número no cuenta toda la historia. Por ejemplo, que un municipio tenga pocas ventas registradas no significa necesariamente que sus habitantes compren menos gaseosas; también puede faltar información en la base de datos. Por eso aprendí que, antes de sacar conclusiones, debo comprobar de dónde vienen los datos y si están completos.

La corrección de los registros me mostró que un pequeño error puede cambiar los resultados de un análisis. Este trabajo me ayudó a conectar lo que hemos estudiado sobre bases de datos con una situación práctica. Para mi formación profesional, me queda la importancia de entregar información clara y confiable antes de usarla para tomar decisiones.

14 Video explicativo

https://www.youtube.com/watch?v=_iVZhdg9qUU&feature=youtu.be

Referencias

American Society for Quality. (s. f.). What is a Pareto chart? <https://asq.org/quality-resources/pareto>

Electric. (s. f.). Getting started with PGLite. <https://pglite.dev/docs/>

PostgreSQL Global Development Group. (s. f.-a). 9.21. Aggregate functions. En PostgreSQL 18 documentation. <https://www.postgresql.org/docs/18/functions-aggregate.html>

PostgreSQL Global Development Group. (s. f.-b). 9.28. System administration functions. En PostgreSQL 18 documentation. <https://www.postgresql.org/docs/18/functions-admin.html>

Soto U., J. E. (s. f.). Algoritmo ETL [Código Python de la actividad de Fundamentos de Bigdata]. Institución Universitaria Pascual Bravo.

Los datos del análisis proceden de colombia-dane-departamentos.csv y script-base-datos-operaciones.sql, suministrados en la actividad. Los cálculos, correcciones y consultas se encuentran en los archivos del proyecto.